데이터 만지기

정석오

제 1 절 데이터 입출력

1.1 데이터 입력 (import)

콘솔에서 직접 자료값을 입력하려면 scan() 함수를 사용한다.

> x <- scan()

1: 1

2: 2

3: 3

4:

Read 3 items

> x

[1] 1 2 3

텍스트 파일의 내용을 읽어들여 벡터로 저장할 때에도 scan() 함수를 사용한다.

```
> x <- scan(file = "c:/mydata/data_x.txt")
> y <- matrix(scan("c:/mydata/data_y.txt"), ncol = 3, byrow = TRUE)</pre>
```

데이터를 직사각형 형태로 정리한 텍스트 파일의 내용을 읽어들여 데이터프레임으로 저장하려면 read.table() 함수를 사용한다.

```
> x <- read.table(file = "table.txt", header = TRUE, sep = " ")
```

csv 파일을 읽어들여 데이터프레임으로 저장하려면 read.csv() 함수를 사용한다.

```
> x <- read.csv(file = "table.csv")</pre>
```

1.2 데이터 내보내기 (export)

print() 함수를 이용해 데이터를 콘솔에 출력할 수 있다.

```
> x <- 1:3
```

> print(x)

[1] 1 2 3

벡터로 저장된 데이터를 외부 파일로 내보내려면 'write()' 함수를 사용한다.

```
> x <- seq(from = 0, to = 1, by = 0.1)
> write(x, file = "output.txt")
```

데이터프레임, 행렬 등과 같이 직사각형 표 형태로 저장/작성된 데이터를 텍스트 파일로 내보내려면 write.table() 함수를, csv 파일로 내보내려면 write.csv() 함수를 이용하다.

```
> x <- matrix(1:20, 4, 5)
> write.table(x, file = "table.txt", row.names = FALSE)
> data(faithful)
> write.csv(faithful, file = "faithful.csv", row.names = FALSE)
```

제 2 절 간단한 데이터 조작

2.1 기준에 따라 데이터 쪼개고 붙이기

2.1.1 split() 함수

데이터셋을 기준 변수에 따라 여러 그룹으로 쪼개어서 새로운 데이터셋을 만들어 주는 함수이다. 아래는 MASS 패키지의 내장 데이터인 Cars93의 MPG.city 변수를 가지고 Origin 변수값(USA, non-USA)에 따라 두 개의 그룹으로 쪼개어 두 개의 성분을 갖는 리스트를 만드는 예이다.

> library(MASS) # for the dataset Cars93

> summary(Cars93)

Manufacture	er Model	Туре	Min.Price	Price
Chevrolet: 8	100 : 1	Compact:16	Min. : 6.70	Min. : 7.40
Ford : 8	190E : 1	Large :11	1st Qu.:10.80	1st Qu.:12.20
Dodge : 6	240 : 1	Midsize:22	Median :14.70	Median :17.70
Mazda : 5	300E : 1	Small :21	Mean :17.13	Mean :19.51
Pontiac : 5	323 : 1	Sporty :14	3rd Qu.:20.30	3rd Qu.:23.30
Buick : 4	535i : 1	Van : 9	Max. :45.40	Max. :61.90
(Other) :57	(Other):87			
Max.Price	MPG.city	MPG.highw	ay	AirBags
Min. : 7.9	Min. :15.00	Min. :20	.00 Driver &	Passenger:16
1st Qu.:14.7	1st Qu.:18.00	1st Qu.:26	.00 Driver on	ly :43
Median :19.6	Median :21.00	Median :28	0.00 None	:34
Mean :21.9	Mean :22.37	Mean :29	.09	
3rd Qu.:25.3	3rd Qu.:25.00	3rd Qu.:31	.00	
Max. :80.0	Max. :46.00	Max. :50	.00	
DriveTrain Cy	rlinders Eng	ineSize	Horsepower	RPM
DriveTrain Cy 4WD :10 3	rlinders Eng : 3 Min.		-	RPM in. :3800
_	: 3 Min.	:1.000 Mi	n. : 55.0 M	
4WD :10 3	: 3 Min.	:1.000 Mi u.:1.800 1s	n. : 55.0 M	in. :3800
4WD :10 3 Front:67 4	: 3 Min.	:1.000 Mi u.:1.800 1s n :2.400 Me	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M	in. :3800 st Qu.:4800
4WD :10 3 Front:67 4 Rear :16 5	: 3 Min. :49 1st Q : 2 Media :31 Mean	:1.000 Mi u.:1.800 1s n :2.400 Me :2.668 Me	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M	in. :3800 st Qu.:4800 edian :5200
4WD :10 3 Front:67 4 Rear :16 5 6 8	: 3 Min. :49 1st Q : 2 Media :31 Mean	:1.000 Mi u.:1.800 1s n :2.400 Me :2.668 Me u.:3.300 3r	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3	in. :3800 st Qu.:4800 edian :5200 ean :5281
4WD :10 3 Front:67 4 Rear :16 5 6 8	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q	:1.000 Mi u.:1.800 1s n :2.400 Me :2.668 Me u.:3.300 3r	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750
4WD :10 3 Front:67 4 Rear :16 5 6 8	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q	:1.000 Mi u.:1.800 1s n :2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 .xx. :300.0 M	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750
4WD :10 3 Front:67 4 Rear :16 5 6 8 rot	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q :ary: 1 Max.	:1.000 Mi u.:1.800 1s n :2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 xx. :300.0 M capacity Pass	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750 ax. :6500
4WD :10 3 Front:67 4 Rear :16 5 6 8 rot Rev.per.mile Min. :1320	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q :ary: 1 Max.	:1.000 Mi u.:1.800 1s n:2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 x. :300.0 M capacity Pass	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750 ax. :6500 engers :2.000
4WD :10 3 Front:67 4 Rear :16 5 6 8 rot Rev.per.mile Min. :1320	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q :ary: 1 Max. Man.trans.ava	:1.000 Mi u.:1.800 1s n:2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma il Fuel.tank. Min. : 9	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 x. :300.0 M capacity Pass 2.20 Min. 3.50 1st Qu	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750 ax. :6500 engers :2.000
4WD :10 3 Front:67 4 Rear :16 5 6 8 rot Rev.per.mile Min. :1320 1st Qu.:1985	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q :ary: 1 Max. Man.trans.ava	:1.000 Mi u.:1.800 1s n:2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma il Fuel.tank. Min. : 9 1st Qu.:14	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 xx. :300.0 M capacity Pass 0.20 Min. 1.50 1st Qu 3.40 Median	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750 ax. :6500 engers :2.000 .:4.000 :5.000
4WD :10 3 Front:67 4 Rear :16 5 6 8 rot Rev.per.mile Min. :1320 1st Qu.:1985 Median :2340	: 3 Min. :49 1st Q : 2 Media :31 Mean : 7 3rd Q :ary: 1 Max. Man.trans.ava	:1.000 Mi u.:1.800 1s n:2.400 Me :2.668 Me u.:3.300 3r :5.700 Ma il Fuel.tank. Min. : 9 1st Qu.:14 Median :16	n. : 55.0 M t Qu.:103.0 1 dian :140.0 M an :143.8 M d Qu.:170.0 3 x. :300.0 M capacity Pass 2.20 Min. 3.50 1st Qu 3.40 Median 3.66 Mean	in. :3800 st Qu.:4800 edian :5200 ean :5281 rd Qu.:5750 ax. :6500 engers :2.000 .:4.000 :5.000

Length	Wheelbase	Width	Turn.circl	e
Min. :141.0	Min. : 90.0	Min. :60.00	Min. :32.	00
1st Qu.:174.0	1st Qu.: 98.0	1st Qu.:67.00	1st Qu.:37.	00
Median :183.0	Median :103.0	Median :69.00	Median :39.	00
Mean :183.2	Mean :103.9	Mean :69.38	Mean :38.	96
3rd Qu.:192.0	3rd Qu.:110.0	3rd Qu.:72.00	3rd Qu.:41.	00
Max. :219.0	Max. :119.0	Max. :78.00	Max. :45.	00
Rear.seat.room	Luggage.room	Weight	Origin	Make
Min. :19.00	Min. : 6.00	Min. :1695	USA :48	Acura Integra: 1
1st Qu.:26.00	1st Qu.:12.00	1st Qu.:2620	non-USA:45	Acura Legend : 1
Median :27.50	Median :14.00	Median :3040		Audi 100 : 1
Mean :27.83	Mean :13.89	Mean :3073		Audi 90 : 1
3rd Qu.:30.00	3rd Qu.:15.00	3rd Qu.:3525		BMW 535i : 1
Max. :36.00	Max. :22.00	Max. :4105		Buick Century: 1
NA's :2	NA's :11			(Other) :87
	Cars93\$MPG.city,	Cars93\$Urigin)	0 . 0	
> str(tmp)			# List of 2	
List of 2				
\$ USA : int	[1:48] 22 19 16	19 16 16 25 25	19 21	
<pre>\$ non-USA: int</pre>	[1:45] 25 18 20	19 22 46 30 24	42 24	

2.1.2 subset() 함수

데이터프레임의 일부 행(row)를 추출할 때는 subset() 함수를 사용한다. 옵션 subset =을 이용해 추출 조건을 지정한다. select = 옵션을 이용하면 추출 대상 변수(열)를 지정할 수 있다. 다음은 내장 데이터 셋인 Cars93에서 지정한 조건에 맞는 데이터를 추출하는 예이다.

```
> subset(Cars93, subset = (MPG.city > 32))
```

Manufacturer Model Type Min.Price Price Max.Price MPG.city MPG.highway

39 Geo Metro Small 6.7 8.4 10.0 46 50

42	Honda	Civic Small	8.4	12.1	:	15.8	42	4	6
80	Subaru	Justy Small	7.3	8.4		9.5	33	3	7
83	Suzuki	Swift Small	7.3	8.6	;	10.0	39	4	3
	AirBags I	DriveTrain Cyl	inders En	gineSi	ze Ho	rsepower	RPM Re	ev.per.mi	le
39	None	Front	3	1	.0	55	5700	37	55
42	Driver only	Front	4	1	.5	102	5900	26	50
80	None	4WD	3	1	.2	73	5600	28	75
83	None	Front	3	1	.3	70	6000	33	60
	Man.trans.ava	ail Fuel.tank.	capacity	Passen	gers 1	Length Wh	neelbas	e Width	
39	3	Yes	10.6		4	151	93	3 63	
42	3	Yes	11.9		4	173	103	3 67	
80	3	Yes	9.2		4	146	90	60	
83	7	Yes	10.6		4	161	93	3 63	
	Turn.circle H	Rear.seat.room	Luggage.	room We	eight	Origin		Make	
39	34	27.5		10	1695	non-USA	Geo	Metro	
42	36	28.0		12	2350	non-USA	Honda	Civic	
80	32	23.5		10	2045	non-USA	Subaru	Justy	
83	34	27.5		10	1965	non-USA	Suzuki	Swift	

> subset(Cars93, select = Model, subset = (MPG.city > 32))

Model

39 Metro

42 Civic

80 Justy

83 Swift

데이터프레임의 특정 열을 제외시킬 때는 subset() 함수의 select = 옵션에 -을 사용한다.

> str(EuStockMarkets)

Time-Series [1:1860, 1:4] from 1991 to 1999: 1629 1614 1607 1621 1618 \dots

- attr(*, "dimnames")=List of 2

..\$: NULL

..\$: chr [1:4] "DAX" "SMI" "CAC" "FTSE"

> cor(EuStockMarkets) DAX SMI CAC FTSE DAX 1.0000000 0.9911539 0.9662274 0.9751778 SMI 0.9911539 1.0000000 0.9468139 0.9899691 CAC 0.9662274 0.9468139 1.0000000 0.9157265 FTSE 0.9751778 0.9899691 0.9157265 1.0000000 > cor(subset(EuStockMarkets, select = -SMI)) # SMI excluded DAX CAC **FTSE** DAX 1.0000000 0.9662274 0.9751778 CAC 0.9662274 1.0000000 0.9157265 FTSE 0.9751778 0.9157265 1.0000000 > cor(subset(EuStockMarkets, select = -c(SMI, CAC))) # SMI and CAC excluded DAX **FTSE** DAX 1.0000000 0.9751778 FTSE 0.9751778 1.0000000 > head(subset(airquality, Temp > 80, select = c(Ozone, Temp)), n = 10) Ozone Temp 29 45 81 35 NA 84 36 NA 85 38 29 82 39 NA 87 71 90 40

> subset(airquality, Day == 1, select = -Temp)

39 87

NA 93

NA 92

82

23

41 42

43

44

Ozone Solar.R Wind Month Day

```
1
      41
            190 7.4
32
            286 8.6
      NA
            269 4.1
62
     135
                        7 1
93
      39
            83 6.9
                        8
                            1
124
      96
            167 6.9
                        9
                            1
```

> head(subset(airquality, select = Ozone:Wind), n = 10)

Ozone Solar.R Wind

194 8.6

2.1.3 merge() 함수

NA

10

지정한 변수를 기준으로 두 데이터프레임을 결합할 때는 merge() 함수를 이용한다. 결합 기준 변수는 by = 옵션에서 지정하는데, 변수명에 ""을 붙여야 함에 유의하자.

```
> merge(a, b, by = "Name", all = TRUE)
   Name score weight
1 Alice
          100
                 55
2
    Ana
         NA
                 60
3 Bianca
        100
                 NA
   Jane
           95
                 70
5 Mary 90
                 NA
```

2.2 apply 계열 함수

행렬 혹은 데이터프레임의 각 행과 열에 대해 같은 작업을 반복적으로 실행해 새로운 벡터를 생성하려면 apply() 함수를 이용한다. apply()의 두 번째 입력값(MARGIN)을 1로 지정하면 각 행에 대해, 2로 지정하면 각 열에 대해 반복 작업을 실행한다.

```
> a <- matrix(1:20, 4, 5)
> a
    [,1] [,2] [,3] [,4] [,5]
[1,]
      1
           5
             9
                  13
                      17
[2,]
         6 10 14 18
[3,]
      3
         7 11
                  15 19
[4,]
         8 12 16
      4
                       20
> apply(a, 1, mean)
                  # to every row
[1] 9 10 11 12
> apply(a, 2, mean) # to every column
[1] 2.5 6.5 10.5 14.5 18.5
```

리스트 객체의 각 성분에 대해 지정한 함수를 적용해 얻은 결과를 새로운 리스트 혹은 벡터로 만들고 싶으면 lapply() 함수, sapply() 함수를 사용한다. lapply는 리스트를, sapply는 벡터를 리턴한다. 다음은 5개의 성분을 갖는 리스트 Hong에 length() 함수를 적용해 각 성분의 벡터 길이를 알려주는 예이다.

```
> Hong <- list(first.name = "Samuel",
             age = 44,
             gender = "M",
             n.child = 2,
             child.gender = c("M", "F"))
> lapply(Hong, length) # returns a list
$first.name
[1] 1
$age
[1] 1
$gender
[1] 1
$n.child
[1] 1
$child.gender
[1] 2
> sapply(Hong, length) # returns a vector
 first.name
                               gender n.child child.gender
                     age
                      1
                                                 1
          1
                                   1
```

특정 변수에 그룹별로 함수를 적용하려면 tapply() 함수를 사용하면 된다. 다음은 Cars93 데이터의 Price 변수의 평균을 Origin별로 계산하는 예제이다.

데이터셋에 포함된 모든 변수에 대해 그룹별로 함수를 적용하려면 by() 함수를 이용한다. 아래 코드는

Cars93에 대해 Origin별로 summary() 함수를 적용한 예이다.

> by(Cars93, Cars93\$Origin, summary)

Cars93\$Origin: U	JSA
-------------------	-----

Manufacture	er Model	Туре	Min.Price	Price
Chevrolet : 8	Achieva : 1	Compact: 7	Min. : 6.90	Min. : 7.40
Ford : 8	Aerostar : 1	Large :11	1st Qu.:11.40	1st Qu.:13.47
Dodge : 6	Astro : 1	Midsize:10	Median :14.50	Median :16.30
Pontiac : 5	Bonneville: 1	Small : 7	Mean :16.54	Mean :18.57
Buick : 4	Camaro : 1	Sporty : 8	3rd Qu.:19.43	3rd Qu.:20.73
Oldsmobile: 4	Capri : 1	Van : 5	Max. :37.50	Max. :40.10
(Other) :13	(Other) :42			
Max.Price	MPG.city	MPG.highway		AirBags
Min. : 7.90	Min. :15.00	Min. :20.00	Driver & Pas	ssenger: 9
1st Qu.:14.97	1st Qu.:18.00	1st Qu.:26.00	Driver only	:23
Median :18.40	Median :20.00	Median :28.00	None	:16
Mean :20.63	Mean :20.96	Mean :28.15		
3rd Qu.:24.50	3rd Qu.:23.00	3rd Qu.:30.00		
Max. :42.70	Max. :31.00	Max. :41.00		
DriveTrain Cyl	inders Engine	Size Hors	epower	RPM
4WD : 5 3	: 0 Min. :	1.300 Min.	: 63.0 Min.	:3800
Front:34 4	:22 1st Qu.:	2.200 1st Qu	.:108.8 1st 0	Ųu.:4750
Rear : 9 5	: 0 Median :	3.000 Median	:143.5 Media	an :4900
6	:20 Mean :	3.067 Mean	:147.5 Mean	:4991
8	: 6 3rd Qu.:	3.800 3rd Qu	.:170.0 3rd 0	Ųu.:5200
rota	ry: 0 Max. :	5.700 Max.	:300.0 Max.	:6500

Rev.per.mile Man.trans.avail Fuel.tank.capacity Passengers
Min. :1320 No :26 Min. :10.00 Min. :2.000

1st Qu.:1771 Yes:22 1st Qu.:15.47 1st Qu.:5.000 Median :2035 Median :16.45 Median :5.000 Mean :2119 Mean :17.05 Mean :5.333

 3rd Qu.:2482
 3rd Qu.:19.05
 3rd Qu.:6.000

 Max. :3285
 Max. :27.00
 Max. :8.000

Ler	Length		Wheelbase		Width		Turn.circle	
Min.	:141.0	Min.	: 90.0	Min.	:63.00	Min.	:32.00	
1st Qu.	:177.0	1st Qu.	:101.0	1st Qu	:68.00	1st Qu	:39.00	
Median	:188.5	Median	:105.0	Median	:71.50	Median	:41.00	
Mean	:188.3	Mean	:105.7	Mean	:70.96	Mean	:40.48	
3rd Qu.	:199.2	3rd Qu.	:111.0	3rd Qu	:74.00	3rd Qu	:43.00	
Max.	:219.0	Max.	:119.0	Max.	:78.00	Max.	:45.00	

Rear.seat.room Luggage.room Weight Origin
Min. :19.00 Min. : 6.00 Min. :1845 USA :48

1st Qu.:26.25 1st Qu.:13.00 1st Qu.:2705 non-USA: 0

Median :28.00 Median :14.50 Median :3282

Mean :28.13 Mean :14.88 Mean :3195

3rd Qu.:30.50 3rd Qu.:17.00 3rd Qu.:3639

Max. :36.00 Max. :22.00 Max. :4105

NA's :1 NA's :6

Make

Buick Century : 1
Buick LeSabre : 1
Buick Riviera : 1
Buick Roadmaster: 1
Cadillac DeVille: 1
Cadillac Seville: 1
(Other) : 42

Cars93\$Origin: non-USA

Manufacturer		Mo	Model Type		Min.Price	Price	
Mazda	: 5	100	: 1	Compact: 9	Min. : 6.70	Min. : 8.00	
Hyundai	: 4	190E	: 1	Large : 0	1st Qu.: 9.10	1st Qu.:11.60	
Nissan	• 4	240	· 1	Midsize·12	Median ·16 30	Median ·19 10	

Toyota : 4 300E : 1 Small :14 Mean :17.76 Mean :20.51 Volkswagen: 4 323 : 1 Sporty: 6 3rd Qu.:22.90 3rd Qu.:26.70 535i Van Honda : 3 : 1 : 4 Max. :45.40 Max. :61.90

MPG.highway

:50.00

AirBags

(Other) :21 (Other):39

Max.Price

:80.00

Max.

Min. : 9.10 Min. :17.00 Min. :21.00 Driver & Passenger: 7
1st Qu.:12.90 1st Qu.:19.00 1st Qu.:25.00 Driver only :20

Median :21.70 Median :22.00 Median :30.00 None :18

Max.

Mean :23.26 Mean :23.87 Mean :30.09 3rd Qu.:28.50 3rd Qu.:26.00 3rd Qu.:33.00

Max.

:46.00

MPG.city

DriveTrain Cylinders EngineSize Horsepower RPM4WD : 5 3 : 3 Min. :1.000 Min. : 55.0 Min. :4500 Front:33 :27 1st Qu.:1.600 1st Qu.:102.0 1st Qu.:5400 4 Rear : 7 Median :2.200 Median :135.0 Median:5600 : 2 :11 Mean :2.242 Mean :139.9 Mean :5590 3rd Qu.:2.800 3rd Qu.:168.0 8 : 1 3rd Qu.:6000 rotary: 1 Max. :4.500 Max. :278.0 Max. :6500

Rev.per.mile Man.trans.avail Fuel.tank.capacity Passengers Min. :1955 No : 6 Min. : 9.20 Min. :2.000 1st Qu.:2325 1st Qu.:13.20 1st Qu.:4.000 Yes:39 Median:2505 Median :15.90 Median :5.000 Mean :2560 Mean :16.25 Mean :4.822 3rd Qu.:2710 3rd Qu.:18.50 3rd Qu.:5.000 Max. :3755 Max. :22.50 Max. :7.000

Length Wheelbase Width Turn.circle Rear.seat.room Min. :146.0 Min. : 90 Min. :60.00 Min. :32.00 Min. :23.00 1st Qu.:170.0 1st Qu.: 97 1st Qu.:66.00 1st Qu.:36.00 1st Qu.:26.00 Median :180.0 Median:103 Median :67.00 Median :37.00 Median :27.50 Mean :177.8 Mean :102 Mean :67.69 Mean :37.33 Mean :27.51

3rd Qu.	Qu.:187.0 3rd Qu.:106		3rd Qu.:70.00		3rd Qu.:39.00		3rd Qu.:28.50		
Max.	:200.0	Max.	:115	Max.	:74.00	Max.	:43.00	Max.	:35.00
								NA's	:1
Luggag	ge.room	We	ight	0:	rigin		Make		
Min.	: 8.00	Min.	:1695	USA	: 0	Acura In	tegra: 1		
1st Qu.	:11.00	1st Qu	.:2475	non-US	SA:45	Acura Le	gend : 1		
Median	:14.00	Median	:2950			Audi 100	: 1		
Mean	:12.85	Mean	:2942			Audi 90	: 1		
3rd Qu.	:14.00	3rd Qu	.:3405			BMW 535i	: 1		
Max.	:17.00	Max.	:4100			Geo Metro	: 1		
NA's	:5					(Other)	:39		

제 3 절 Tidyverse 패키지




그림 3.1: tidyverse 패키지 https://www.tidyverse.org/

데이터 과학을 위해 디자인된 R-패키지의 모음으로서, 포함되어 있는 모든 패키지는 기본 디자인 철학, 문법 및 데이터 구조를 공유한다. 핵심 패키지는 다음과 같다. ggplot2, dplyr, tidyr, readr, purrr, tibble, stringr, forcats

```
> #install.packages("tidyverse")
```

> library(tidyverse)

제 4 절 ggplot2를 이용한 데이터시각화

이 절에서 예제 데이터로 사용할 mpg 데이터셋을 로드하자.

> data(mpg)


4.1 산점도

ggplot2 패키지에서 산점도를 그리는 기본 방법은 다음과 같다.

```
ggplot(data = <DATA>) +
     <GEOM_FUNCTION>(mapping = aes(<MAPPINGS>))
```


mpg 데이터셋의 배기량(displ)과 고속도로연비(hwy) 간의 산점도를 그려보자.


```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy))
```




geom_point() 함수는 산점도를 그려주는 역할을 한다. 함수 내에 mapping = 인수를 이용해 시각화 대상 변수를 지정하는데, aes()와 함께 사용한다. geom_point() 함수 내의 인수를 조정해 다양한 변형 또는 응용이 가능하다.

```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy), color = "blue")
```







```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy, alpha = class))
```




```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy, shape = class))
```




```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy, size = cyl))
```






facet_wrap() 함수를 사용하면 지정한 범주형 변수의 값별로 산점도를 따로 그릴 수 있다. 두 개의 범주형 변수값의 조합별로 산점도를 따로 그리려면 facet_grid() 함수를 사용하면 된다.

```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy)) +
facet_wrap(~ class, nrow = 2)
```




```
> ggplot(data = mpg) +
    geom_point(mapping = aes(x = displ, y = hwy)) +
    facet_grid(drv ~ cyl)
```




4.2 Geometric objects


geom_ 계열 함수는 데이터를 시각화할 방법(또는 결과적으로 생성되는 객체의 종류)을 지정해준다.

```
> ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy))
```






```
> ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
    geom_point() +
    geom_smooth()
```




다양한 방식으로 응용한 예들을 살펴보자.


```
> ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
geom_point(mapping = aes(color = class)) +
geom_smooth()
```



```
> ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
geom_point(mapping = aes(color = class)) +
geom_smooth(se = FALSE)
```



```
> ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
   geom_point(mapping = aes(color = class)) +
   geom_smooth(
   data = filter(mpg, class == "subcompact"),
   se = FALSE)
```




4.3 간단한 통계 분석 결과를 시각화


내장 데이터 diamonds를 로드하자.


> data(diamonds)


다이아몬드 품질(cut)별 분포를 살펴보자.


```
> ggplot(data = diamonds) +
geom_bar(mapping = aes(x = cut))
```












position는 막대를 표시하는 방식을 지정하는 인수이다.


```
> d <- ggplot(data = diamonds, mapping = aes(x = cut, fill = clarity))</pre>
```

- > d + geom_bar(position = "fill")
- > d + geom_bar(position = "dodge")

> d + geom_bar(alpha = 1/5, position = "identity")




```
> ggplot(data = mpg) +
   geom_point(
   mapping = aes(x = displ, y = hwy),
   position = "jitter"
)
```



이런 그림도 가능하다.


```
> ggplot(data = diamonds) +
   stat_summary(
     mapping = aes(x = cut, y = depth),
     fun.ymin = min,
     fun.ymax = max,
     fun.y = median
)
```



4.4 좌표축 다루기


coord_flip() 함수는 가로축과 세로축을 바꿔준다.

```
> m <- ggplot(data = mpg, mapping = aes(x = class, y = hwy))
> m + geom_boxplot() # Not good
> m +
    geom_boxplot() +
    coord_flip()
```




극좌표로 나타내고 싶으면 coord_polar() 함수를 사용한다.

```
> dbar <- ggplot(data = diamonds) +
    geom_bar(
        mapping = aes(x = cut, fill = cut),
        show.legend = FALSE,
        width = 1
    ) +
        theme(aspect.ratio = 1) +
        labs(x = NULL, y = NULL)
> dbar
> dbar + coord_flip()
> dbar + coord_polar() # Coxcomb chart
```




coord_fixed() 함수는 가로축과 세로축의 비율을 지정한 값으로 고정시킨다.

```
> ggplot(data = mpg, mapping = aes(x = cty, y = hwy)) +
    geom_point() +
    geom_abline()
```



```
> ggplot(data = mpg, mapping = aes(x = cty, y = hwy)) +
    geom_point() +
    geom_abline() +
    coord_fixed() # coord_fixed(ratio = 1): default
```



4.5 Layered grammar

제 5 절 dplyr package

5.1 dplyr is...

데이터 munging(또는 wrangling)은 데이터 전처리, 파싱, 필터링과 같이 분석가가 원하는 형태로 데이터 를 변형하고 이리저리 핸들링하는 행위를 의미하는 신조어이다.

(Wikipedia: https://en.wikipedia.org/wiki/Data_wrangling)

dplyr 패키지는 하들리위컴(Hadley Wickham)이 최근 작성한 데이터 처리에 특화된 패키지이다. 하들리위컴이 같은 목적으로 작성한 패키지인 plyr는 모든 함수가 R로 작성되어 있어 속도가 느린 문제가 있었으나, dplyr은 C++로 작성되었기 때문에 매우 빠른 속도로 데이터 처리를 수행할 수 있게 되었다.

이 패키지를 이용하면 코드 작성이 직관적이고 가독성이 좋은 장점(특히 pipe 연산자를 이용한 chaining syntax를 이용 시)이 있다. 다만 dplyr 패키지 내에 몇몇 base 함수와 겹치는 이름의 함수가 있어 masking 이 일어남에 주의해야 한다 (filter(), lag(), intersect(), setdiff(), setequal(), union() 등).

또한 plyr 패키지와 동시에 사용하는 경우 masking 문제에 더욱 유의할 필요가 있다. 굳이 동시에 사용하려면 plyr을 먼저 로드하기를 추천한다.

다음 절부터 사용할 예제 데이터인 nycflights13 패키지의 flights 데이터셋을 로드하자.

- > #install.packages("nycflights13")
- > library(nycflights13)
- > data(flights)

5.2 기본 함수들

• filter(): 지정 조건에 맞는 관측치 추출

• arrange(): 지정 조건에 따라 관측치 정렬

● select(): 변수 추출

• mutate(): 기존 변수를 이용해 새로운 변수 생성

• summarize(): 요약 정보 추출

• group_by(): 지정 변수에 따라 정의된 그룹별로 적용 범위를 제한

5.2.1 filter() 함수

> filter(flights, month == 1, day == 1)

A tibble: 842 × 19

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time
	<int></int>	<int></int>	<int></int>	<int></int>	<int></int>	<dbl></dbl>	<int></int>	<int></int>
1	2013	1	1	517	515	2	830	819
2	2013	1	1	533	529	4	850	830
3	2013	1	1	542	540	2	923	850
4	2013	1	1	544	545	-1	1004	1022
5	2013	1	1	554	600	-6	812	837
6	2013	1	1	554	558	-4	740	728
7	2013	1	1	555	600	-5	913	854
8	2013	1	1	557	600	-3	709	723
9	2013	1	1	557	600	-3	838	846
10	2013	1	1	558	600	-2	753	745

- # ... with 832 more rows, and 11 more variables: arr_delay <dbl>, carrier <chr>,
- # flight <int>, tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>,
- # distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
- > filter(flights, month == 11 | month == 12)
- # A tibble: $55,403 \times 19$

day dep_time sched_dep_time dep_delay arr_time sched_arr_time year month <int> <int> <int> <int> <int> <dbl> <int> <int> 1 2013 2 2013 3 2013 -5 4 2013 -6 5 2013 -3 6 2013 -11 7 2013 -10 8 2013 -6 9 2013 -6

- 10 2013 11 1 554 600 -6 749 751
- # ... with 55,393 more rows, and 11 more variables: arr_delay <dbl>,
- # carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
- # air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
- > filter(flights, month %in% c(11, 12))
- # A tibble: 55,403 × 19

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time
	<int></int>	<int></int>	<int></int>	<int></int>	<int></int>	<dbl></dbl>	<int></int>	<int></int>
1	2013	11	1	5	2359	6	352	345
2	2013	11	1	35	2250	105	123	2356
3	2013	11	1	455	500	-5	641	651
4	2013	11	1	539	545	-6	856	827
5	2013	11	1	542	545	-3	831	855
6	2013	11	1	549	600	-11	912	923
7	2013	11	1	550	600	-10	705	659
8	2013	11	1	554	600	-6	659	701
9	2013	11	1	554	600	-6	826	827
10	2013	11	1	554	600	-6	749	751

^{# ...} with 55,393 more rows, and 11 more variables: arr_delay <dbl>,

5.2.2 arrange() 함수

> arrange(flights, year, month, day)

A tibble: 336,776 × 19

year month day dep_time sched_dep_time dep_delay arr_time sched_arr_time <int> <int> <int> <int> <int> <dbl> <int> <int> 1 2013 1 517 2 830 819 1 515 2 2013 533 529 4 850 830 1 1 3 2013 1 1 542 540 2 923 850

[#] carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,

[#] air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>

4	2013	1	1	544	545	-1	1004	1022
5	2013	1	1	554	600	-6	812	837
6	2013	1	1	554	558	-4	740	728
7	2013	1	1	555	600	-5	913	854
8	2013	1	1	557	600	-3	709	723
9	2013	1	1	557	600	-3	838	846
10	2013	1	1	558	600	-2	753	745

^{# ...} with 336,766 more rows, and 11 more variables: arr_delay <dbl>,

A tibble: $336,776 \times 19$

day dep_time sched_dep_time dep_delay arr_time sched_arr_time <int> <int> <int> <int> <dbl><int> <int> <int> 1 2013 2 2013

5.2.3 select() 함수

[#] carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,

[#] air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>

> arrange(flights, desc(arr_delay)) # 내림차순 정렬

^{# ...} with 336,766 more rows, and 11 more variables: arr_delay <dbl>,

[#] carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,

[#] air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>

> select(flights, year, month, day)

```
# A tibble: 336,776 × 3
```

year month day

<int> <int> <int>

- 1 2013 1 1
- 2 2013 1 1
- 3 2013 1 1
- 4 2013 1 1
- 5 2013 1 1
- 6 2013 1 1
- 7 2013 1 1
- . _----
- 9 2013 1 1

2013

- 10 2013 1 1
- # ... with 336,766 more rows

1

1

- > select(flights, year:day)
- # A tibble: $336,776 \times 3$

year month day

<int> <int> <int>

- 1 2013 1
- 2 2013 1 1
- 3 2013 1 1
- 4 2013 1 1
- 5 2013 1
- 6 2013 1 1
- 7 2013 1 1
- 8 2013 1 1
- 9 2013 1 1
- 10 2013 1 1
- # ... with 336,766 more rows
- > select(flights, -(year:day))
- # A tibble: 336,776 × 16

dep_time sched_dep_time dep_delay arr_time sched_arr_time arr_delay carrier

	<int></int>	<int></int>	<dbl></dbl>	<int></int>	<int></int>	<dbl> <chr></chr></dbl>
1	517	515	2	830	819	11 UA
2	533	529	4	850	830	20 UA
3	542	540	2	923	850	33 AA
4	544	545	-1	1004	1022	-18 B6
5	554	600	-6	812	837	-25 DL
6	554	558	-4	740	728	12 UA
7	555	600	-5	913	854	19 B6
8	557	600	-3	709	723	-14 EV
9	557	600	-3	838	846	-8 B6
10	558	600	-2	753	745	8 AA

^{# ...} with 336,766 more rows, and 9 more variables: flight <int>, tailnum <chr>,

A tibble: $336,776 \times 19$

	time_hour		air_time	year	month	day	dep_time	sched_dep_time
	<dttm></dttm>		<dbl></dbl>	<int></int>	<int></int>	<int></int>	<int></int>	<int></int>
1	2013-01-01	05:00:00	227	2013	1	1	517	515
2	2013-01-01	05:00:00	227	2013	1	1	533	529
3	2013-01-01	05:00:00	160	2013	1	1	542	540
4	2013-01-01	05:00:00	183	2013	1	1	544	545
5	2013-01-01	06:00:00	116	2013	1	1	554	600
6	2013-01-01	05:00:00	150	2013	1	1	554	558
7	2013-01-01	06:00:00	158	2013	1	1	555	600
8	2013-01-01	06:00:00	53	2013	1	1	557	600
9	2013-01-01	06:00:00	140	2013	1	1	557	600
10	2013-01-01	06:00:00	138	2013	1	1	558	600

[#] ... with 336,766 more rows, and 12 more variables: dep_delay <dbl>,

[#] origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,

[#] minute <dbl>, time_hour <dttm>

> select(flights, time_hour, air_time, everything())

[#] arr_time <int>, sched_arr_time <int>, arr_delay <dbl>, carrier <chr>,

[#] flight <int>, tailnum <chr>, origin <chr>, dest <chr>, distance <dbl>,

- # hour <dbl>, minute <dbl>
- > # everything() helper function moves two variables to the start of the data frame everything() 이외의 유용한 Helper 함수들은 다음과 같은 것들이 있다.
 - starts_with("abc"): abc로 시작되는 변수
 - ends_with("xyz"): xyz로 끝나는 변수
 - contains("ijk"): ijk를 포함한 변수
 - num_range("x", 1:3): x1, x2, x3

5.2.4 rename() 함수

- > rename(flights, tail_num = tailnum)
- # A tibble: 336,776 × 19

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time
	<int></int>	<int></int>	<int></int>	<int></int>	<int></int>	<dbl></dbl>	<int></int>	<int></int>
1	2013	1	1	517	515	2	830	819
2	2013	1	1	533	529	4	850	830
3	2013	1	1	542	540	2	923	850
4	2013	1	1	544	545	-1	1004	1022
5	2013	1	1	554	600	-6	812	837
6	2013	1	1	554	558	-4	740	728
7	2013	1	1	555	600	-5	913	854
8	2013	1	1	557	600	-3	709	723
9	2013	1	1	557	600	-3	838	846
10	2013	1	1	558	600	-2	753	745

- # ... with 336,766 more rows, and 11 more variables: arr_delay <dbl>,
- # carrier <chr>, flight <int>, tail_num <chr>, origin <chr>, dest <chr>,
- # air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>

5.2.5 mutate() 함수

A tibble: 336,776 × 10

	year	month	day	<pre>dep_delay</pre>	arr_delay	distance	air_time	gain	hours
	<int></int>	<int></int>	<int></int>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>
1	2013	1	1	2	11	1400	227	9	3.78
2	2013	1	1	4	20	1416	227	16	3.78
3	2013	1	1	2	33	1089	160	31	2.67
4	2013	1	1	-1	-18	1576	183	-17	3.05
5	2013	1	1	-6	-25	762	116	-19	1.93
6	2013	1	1	-4	12	719	150	16	2.5
7	2013	1	1	-5	19	1065	158	24	2.63
8	2013	1	1	-3	-14	229	53	-11	0.883
9	2013	1	1	-3	-8	944	140	-5	2.33
10	2013	1	1	-2	8	733	138	10	2.3

... with 336,766 more rows, and 1 more variable: gain_per_hour <dbl>

새로 만든 변수만 남겨놓고 싶으면 transmute() 함수를 이용한다.

A tibble: 336,776 \times 3

```
gain hours gain_per_hour
   <dbl> <dbl>
                       <dbl>
 1
       9 3.78
                        2.38
 2
      16 3.78
                        4.23
      31 2.67
 3
                       11.6
 4
     -17 3.05
                       -5.57
 5
     -19 1.93
                       -9.83
     16 2.5
 6
                       6.4
 7
     24 2.63
                        9.11
     -11 0.883
                      -12.5
 8
 9
      -5 2.33
                       -2.14
      10 2.3
10
                        4.35
# ... with 336,766 more rows
```

5.2.6 summarise()를 이용한 그룹별 요약

```
> summarise(flights, delay = mean(dep_delay, na.rm = TRUE))
# A tibble: 1 × 1
 delay
  <dbl>
1 12.6
> by_month <- group_by(flights, year, month)</pre>
> summarise(by_month, delay = mean(dep_delay, na.rm = TRUE))
# A tibble: 12 × 3
# Groups: year [1]
    year month delay
   <int> <int> <dbl>
 1 2013
            1 10.0
 2 2013
             2 10.8
 3 2013
             3 13.2
 4 2013
             4 13.9
```

```
5 2013
           5 13.0
 6 2013
           6 20.8
 7 2013
           7 21.7
 8 2013
           8 12.6
9 2013
           9 6.72
10 2013
           10 6.24
11 2013
           11 5.44
12 2013
           12 16.6
```

5.3 Pipe 연산자

파이프 연산자(%>%)는 magrittr 패키지에서 제공하는 기능으로 코드의 가독성 및 작성 시 편의성을 제고해 준다.

